I-SUNS: Zadanie č. 2
Stromy, stroje, hlasovania a redukcia dimenzie

Ivan Yachmenov

November 2026

Úvod

Cieľom zadania je predpovedať koncentráciu oxidu uhoľnatého **co** (mg/m³) vo vzduchu z odoziev piatich chemických senzorov, teploty, vlhkosti a času merania. Výstup je spojité číslo, ide o **regresiu**. Dataset má 9 507 záznamov a 14 stĺpcov. Riešenie je v notebooku `assignment.ipynb`, použité knižnice sú **pandas**, **scikit-learn** a **matplotlib**.

Modely hodnotím pomocou **MSE** (stredná kvadratická chyba), **RMSE** (jej odmocnina, v mg/m³) a $\mathbf{R^2}$ (1 je dokonalá predikcia, 0 znamená, že model nie je lepší než priemer, hodnota môže byť aj záporná), vždy na trénovacej aj testovacej množine.

1 Príprava dát

1.1 Popis dát

Súbor `air_quality.csv` má 9 507 riadkov a 14 stĺpcov, jeden riadok je jedna hodina merania.

stĺpec	význam	hodnoty
instant	index záznamu (ID)	1 až 9 507
date	dátum merania	YYYY-MM-DD, 391 dní
month	mesiac	1 až 12
hour	hodina dňa	0 až 23
weekday	deň v týždni	0 až 6, 0 je nedeľa
season	ročné obdobie (text)	winter, spring, summer, autumn
sensor_co	odozva senzora na CO	600 až 2 100, bez jednotky
sensor_nmhc	odozva senzora na nemetánové uhľovodíky	350 až 2 250
sensor_nox	odozva senzora na oxidy dusíka	300 až 2 700
sensor_no2	odozva senzora na NO_2	550 až 2 800
sensor_o3	odozva senzora na ozón	200 až 2 550
temperature	teplota vzduchu	-5 až 40 °C
humidity	relatívna vlhkosť	0 až 100 %
co	**výstup**: koncentrácia CO z referenčného analyzátora	mg/m³

Vstupy sú teda päť senzorov, dve meteorologické veličiny a čas (mesiac, hodina, deň, ročné obdobie). Z prieskumu (`info`, `isna`, `nunique`, `describe` s porovnaním oproti rozsahom z popisu stĺpcov, `value_counts`): **season** má presne 4 povolené hodnoty a sedí s mesiacom, **month** a **weekday** sedia s **date**, všetky senzory a **humidity** sú v povolenom rozsahu, **temperature** má maximum 44,6 °C nad povolených 40.

1.2 Čistenie dát

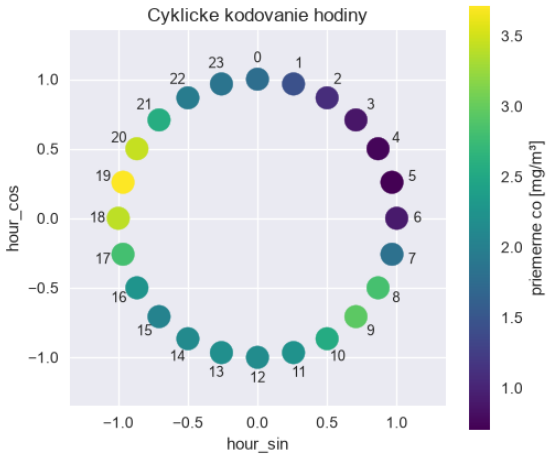
Poradie krokov a počet riadkov po každom z nich:

1. **Duplikáty**: 150 riadkov zhodných vo všetkých 14 stĺpcoch (aj s rovnakým **instant**), odstránené cez `drop_duplicates`. 9 507 → 9 357 riadkov.
2. **Null hodnoty**: v 368 riadkoch chýba všetkých sedem meraní naraz (päť senzorov, **temperature**, **humidity**), ide o výpadok stanice. V 1 716 riadkoch chýba výstup **co**. Tieto riadky som odstránil cez `dropna`, spolu 2 013. Dopĺňať sedem hodnôt naraz alebo cieľovú premennú by bolo vymýšľanie dát. 9 357 → 7 344 riadkov.
3. **Outliery podľa popisu stĺpcov**: jediný stĺpec mimo rozsahu je **temperature** (60 hodnôt nad 40 °C v surových dátach, po predchádzajúcich krokoch 47 riadkov), odstránené. 7 344 → **7 297 riadkov**.
4. **Štatistické outliery** (IQR) som ponechal: 22 riadkov s **co** nad Q3 + 3·IQR (medián 8,7 mg/m³) má v tých istých hodinách vysoké aj **sensor_co** a **sensor_nmhc** a medián hodiny 18 až 19, je to večerná dopravná špička, teda reálne znečistenie, nie chyba merania.
5. **Odstránené stĺpce**: **instant** je len poradové číslo a **date** má 391 hodnôt, pričom mesiac a deň v týždni z neho už sú v **month** a **weekday**.

Spolu odstránených 2 210 riadkov (23 percent, väčšinou riadky bez **co**). Zostalo **7 297 riadkov** a 12 stĺpcov: 11 vstupov a výstup **co**.

1.3 Kódovanie

Stĺpce **hour**, **month**, **weekday** sú cyklické (po 23. hodine je 0.), one-hot by pridal 43 stĺpcov. Použil som **cyklické kódovanie** $\sin(2\pi x/T)$ a $\cos(2\pi x/T)$ s periódou 24, 12 a 7: každý stĺpec sa zmení na dva a hodina 23 je blízko hodiny 0. Stĺpec **season** (4 hodnoty) je kódovaný **one-hot**. Po kódovaní je **17 vstupov**: **sensor_co**, **sensor_nmhc**, **sensor_nox**, **sensor_no2**, **sensor_o3**, **temperature**, **humidity**, **hour_sin**, **hour_cos**, **month_sin**, **month_cos**, **weekday_sin**, **weekday_cos**, **season_winter**, **season_spring**, **season_summer**, **season_autumn**, a výstup **co**.



Obr. 1: Hodiny po cyklickom kódovaní, farba je priemerné **co**. Vidno rannú a večernú dopravnú špičku.

1.4 Rozdelenie a normalizácia

Dáta som rozdelil na trénovaciu (80 percent, 5 837 riadkov) a testovaciu (20 percent, 1 460 riadkov) množinu, potom na vstupy X a výstup y = **co**. Vstupy som štandardizoval (`StandardScaler`) so scalerom nastaveným len na trénovacej množine, výstup zostal v mg/m³. Stromové modely trénujem na neškálovaných vstupoch (strom porovnáva s prahom, škálovanie nemá vplyv a prahy sa dajú čítať), SVM na škálovaných, lebo pracuje so vzdialenosťami.

2 Modely

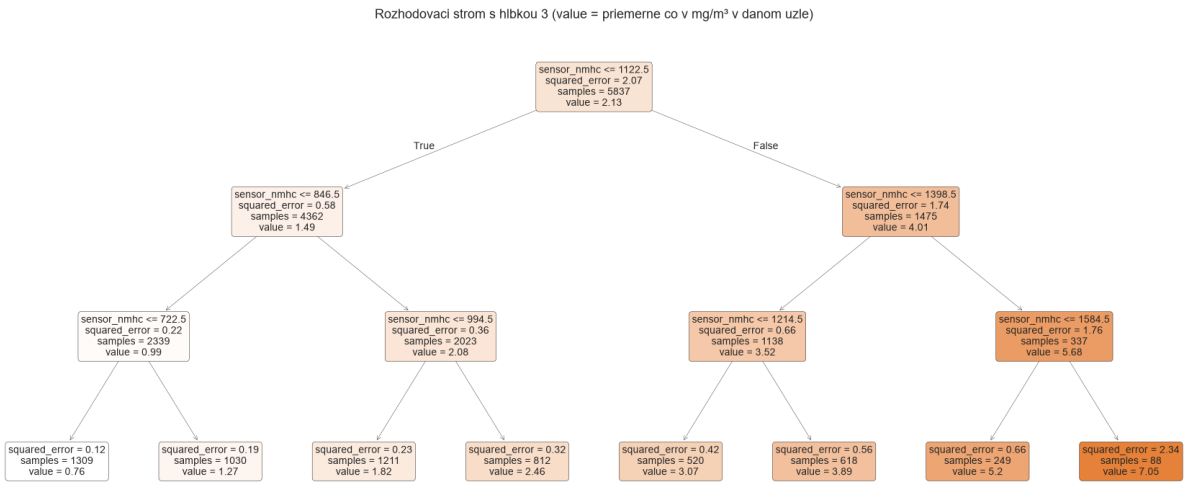
2.1 Rozhodovací strom

Strom bez obmedzenia má 4 082 listov, R^2 train 1,000 a test 0,884, teda je pretrénovaný. Skúšal som obmedziť maximálnu hĺbku a minimálny počet riadkov v liste (pre-pruning).

model	listov	RMSE train	RMSE test	R2 train	R2 test
max_depth=3	8	0.5590	0.5468	0.8490	0.8563
max_depth=4	16	0.4985	0.5034	0.8799	0.8782
max_depth=5	32	0.4530	0.4593	0.9009	0.8986
max_depth=6	63	0.4178	0.4476	0.9157	0.9037
max_depth=8	232	0.3426	0.4496	0.9433	0.9029
max_depth=10	680	0.2597	0.4593	0.9674	0.8986
max_depth=12	1517	0.1750	0.4892	0.9852	0.8850
max_depth=None	4082	0.0000	0.4915	1.0000	0.8839
min_samples_leaf=5	921	0.2605	0.4619	0.9672	0.8975
min_samples_leaf=10	456	0.3367	0.4383	0.9452	0.9077
min_samples_leaf=20	231	0.3819	0.4334	0.9295	0.9098
min_samples_leaf=50	89	0.4494	0.4649	0.9024	0.8962

Obr. 2: Rozhodovací strom podľa obmedzenia hĺbky a minimálneho počtu riadkov v liste.

Najlepší je strom s **min_samples_leaf = 20** (231 listov): **R^2 test 0,910**, RMSE 0,433 mg/m³, rozdiel train a test len 0,02. Pre vizualizáciu som natrénoval menší strom s **hĺbkou 3** (8 listov, R^2 test 0,856).

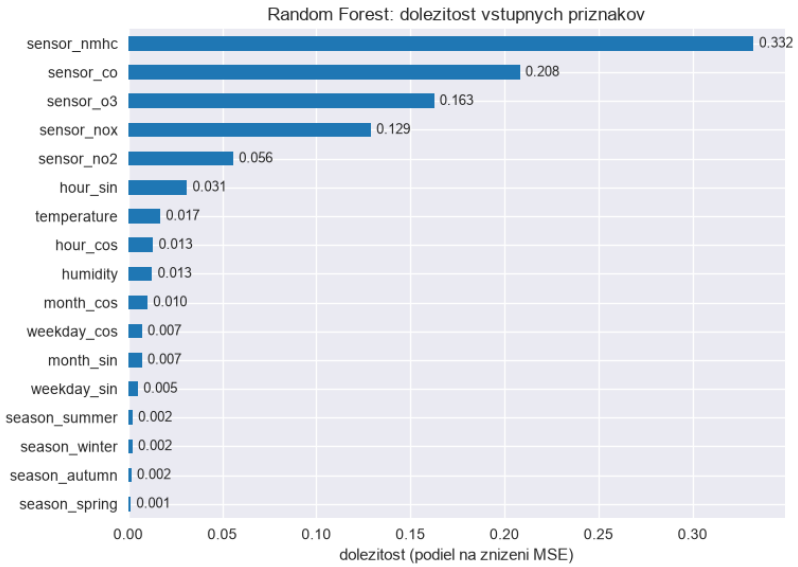


Obr. 3: Rozhodovací strom s hĺbkou 3, value je priemerné **co** v mg/m³ v uzle.

Strom sa vo všetkých siedmich uzloch pýta na **sensor_nmhc**, najinformatívnejší vstup. Koreň delí prahom 1 122,5: pod ním je priemerné **co** 1,49, nad ním 4,01 mg/m³. Listy idú zľava doprava od 0,76 po 7,05 mg/m³, strom je schodovitá aproximácia rastúcej závislosti **co** od senzora. Najväčšiu chybu má pravý krajný list (len 88 riadkov, práve tam sú špičky znečistenia).

2.2 Ensemble model: Random Forest

Zvolil som **Random Forest** (bagging): 300 stromov, každý trénovaný na náhodnom výbere riadkov s opakovaním a v každom uzle vyberá z náhodných 4 zo 17 príznakov (`max_features="sqrt"`). Výsledok je priemer stromov. Dosiahol **R^2 test 0,940**, RMSE 0,353 mg/m³ (train 0,991, stromy v lese rastú bez obmedzenia, ale priemer sa na teste pretrénovaním neprejaví).



Obr. 4: Dôležitosť vstupných príznakov podľa Random Forestu (podiel na znížení MSE, súčet 1).

Najdôležitejšie sú senzory (**sensor_nmhc** 33 percent, **sensor_co** 21, **sensor_o3** 16, **sensor_nox** 13, **sensor_no2** 6, spolu 89 percent), potom hodina (4 percentá), teplota a vlhkosť (po 1 až 2 percentá). Mesiac, deň v týždni a ročné obdobie sú pod 1 percento. Dôležitosť je rozdelená medzi senzory, lebo spolu silno korelujú a nesú podobnú informáciu.

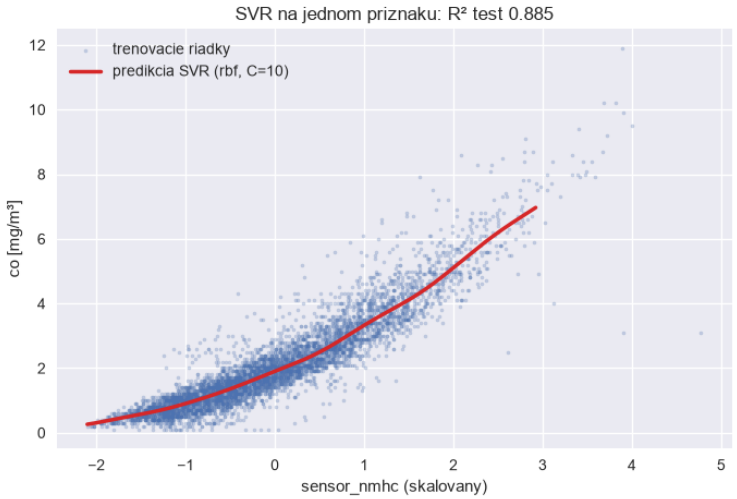
2.3 SVM

Použil som `SVR` s **RBF jadrom** na škálovaných vstupoch, epsilon = 0,1 (rozlíšenie merania **co**). Na všetkých 17 príznakoch som prešiel C od 1 po 30, gamma od 0,01 po 0,3 a porovnal tri druhy jadra.

model	RMSE train	RMSE test	R2 train	R2 test
SVR rbf, C=1	0.3424	0.3328	0.9434	0.9468
SVR rbf, C=3	0.3096	0.3098	0.9537	0.9539
SVR rbf, C=10	0.2735	0.2979	0.9639	0.9573
SVR rbf, C=30	0.2335	0.2926	0.9737	0.9589
SVR linear, C=10	0.4843	0.4423	0.8867	0.9060
SVR poly (stupen 2), C=10	0.8144	0.7658	0.6795	0.7182

Obr. 5: Vplyv C a druhu jadra na všetkých 17 príznakoch.

Zvolil som **C = 10, gamma = scale**: **R^2 test 0,957**, RMSE 0,298 mg/m³, rozdiel train a test len 0,007. Väčšie C alebo gamma zlepšujú test už len o tisíciny a zväčšujú pretrénovanie. Lineárne jadro dosiahlo 0,906, vzťah senzorov a CO je nelineárny.



Obr. 6: Samostatný SVR (RBF, C = 10) natrénovaný len na jednom príznaku **sensor_nmhc** (R^2 test 0,885, nie model zo 17 príznakov), body sú trénovacie riadky.

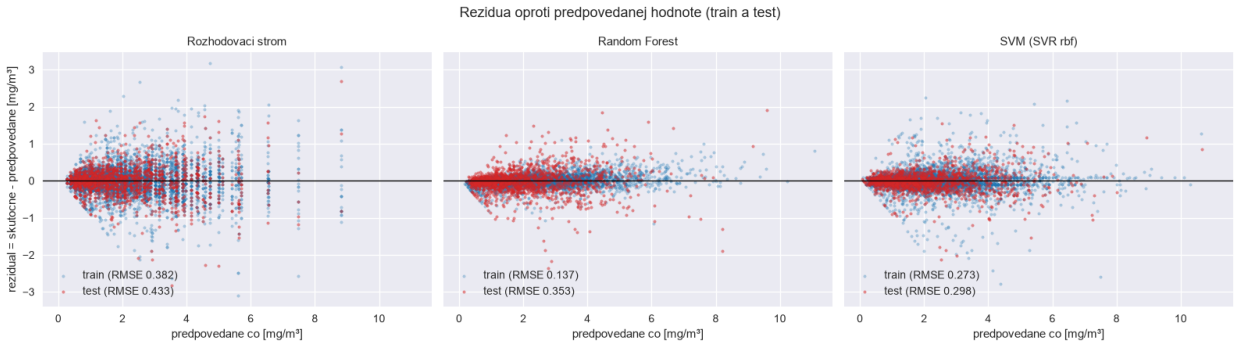
Čiara sleduje tvar dát: pri nízkom signáli rastie pomaly, pri vysokom čoraz rýchlejšie, lebo senzor saturuje. Priamka by tento tvar neopísala, preto lineárne jadro dopadlo horšie.

2.4 Porovnanie modelov a rezíduá

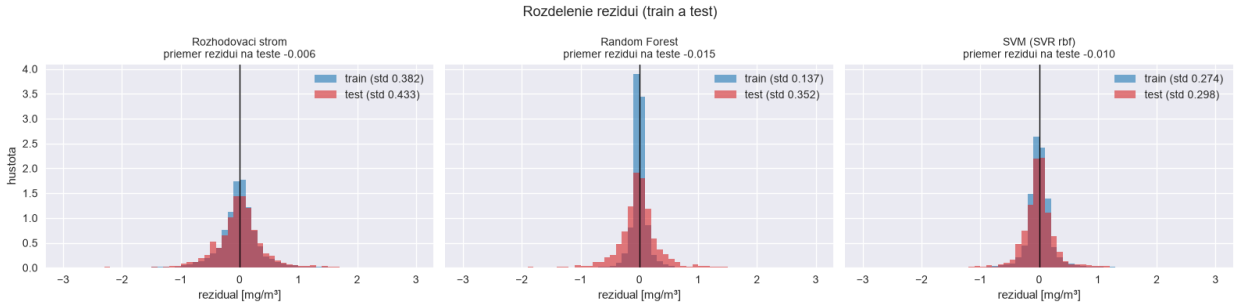
model	MSE train	MSE test	RMSE train	RMSE test	R2 train	R2 test	R2 rozdiel (train - test)
Rozhodovaci strom	0.1459	0.1878	0.3819	0.4334	0.9295	0.9098	0.0197
Random Forest	0.0187	0.1243	0.1366	0.3526	0.9910	0.9403	0.0507
SVM (SVR rbf)	0.0748	0.0888	0.2735	0.2979	0.9639	0.9573	0.0066

Obr. 7: Porovnanie troch modelov na trénovacej a testovacej množine.

Všetky modely majú R^2 nad 0,9, poradie na teste je **SVM 0,957, Random Forest 0,940, strom 0,910**. Rezíduum je skutočná hodnota mínus predpovedaná; kreslím ho oproti predpovedanej hodnote, kde sa ukáže každý systematický vzor.



Obr. 8: Rezíduá oproti predpovedanej hodnote, modrá trénovacia a červená testovacia množina.



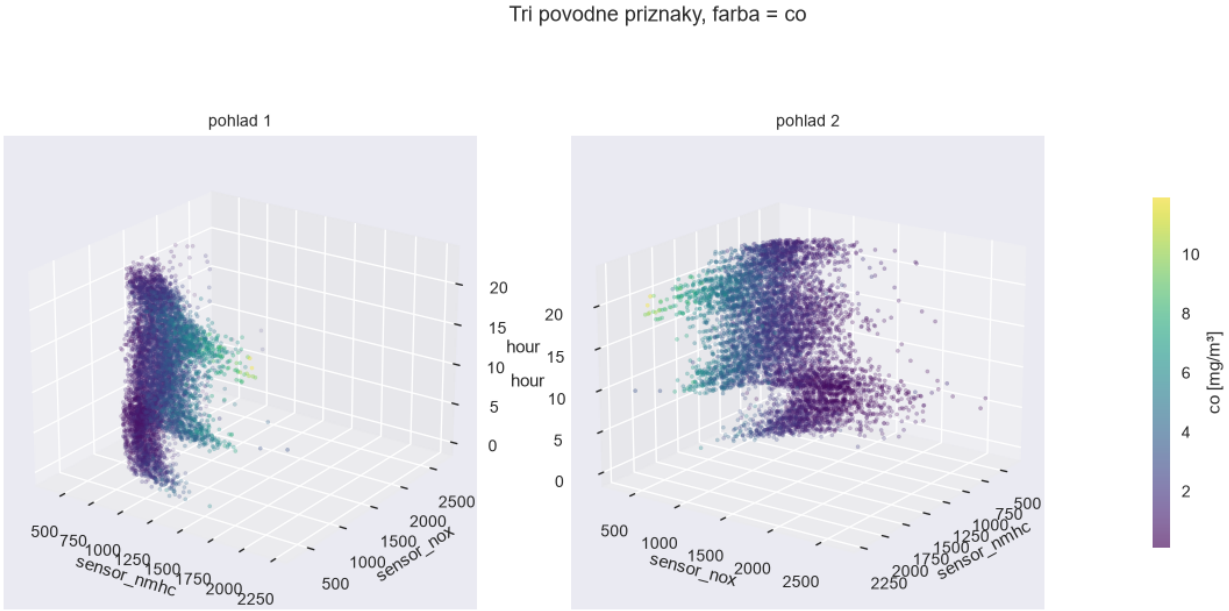
Obr. 9: Rozdelenie rezíduí na trénovacej a testovacej množine.

Rezíduá všetkých modelov sú sústredené okolo nuly (priemer na teste od $-0{,}015$ do $-0{,}006$) so symetrickým rozdelením, modely teda systematicky nenadhodnocujú ani nepodhodnocujú. Líšia sa rozptylom na teste: 0,43 (strom), 0,35 (les), 0,30 (SVM). Strom má v trénovacích bodoch zvislé pásy, lebo vracia len 231 hodnôt, po jednej na list. Random Forest má modré body výrazne bližšie k nule než červené (train 0,14 oproti test 0,35), SVM má modré a červené takmer prekryté. Spoločný vzor: rozptyl rastie s predikciou, pri **co** nad 5 mg/m³ je priemerná chyba 0,44 až 0,67 oproti 0,14 až 0,22 pri nízkych hodnotách. Vysokých koncentrácií je v dátach málo (60 testovacích riadkov nad 5) a senzory pri nich saturujú. SVM vyhral, lebo závislosť je plynulá a RBF jadro ju opíše hladkou funkciou, kým stromy ju skladajú zo schodov. Pre časť 4 beriem **SVM (RBF, C = 10)**.

3 Redukcia dimenzie

3.1 3D graf vybraných príznakov

Pred normalizáciou som vybral **sensor_nmhc** (najsilnejšia kladná korelácia s **co**, 0,92), **sensor_nox** (najsilnejšia záporná, $-0{,}70$) a **hour** (časový príznak s najväčším vplyvom, 0,36).



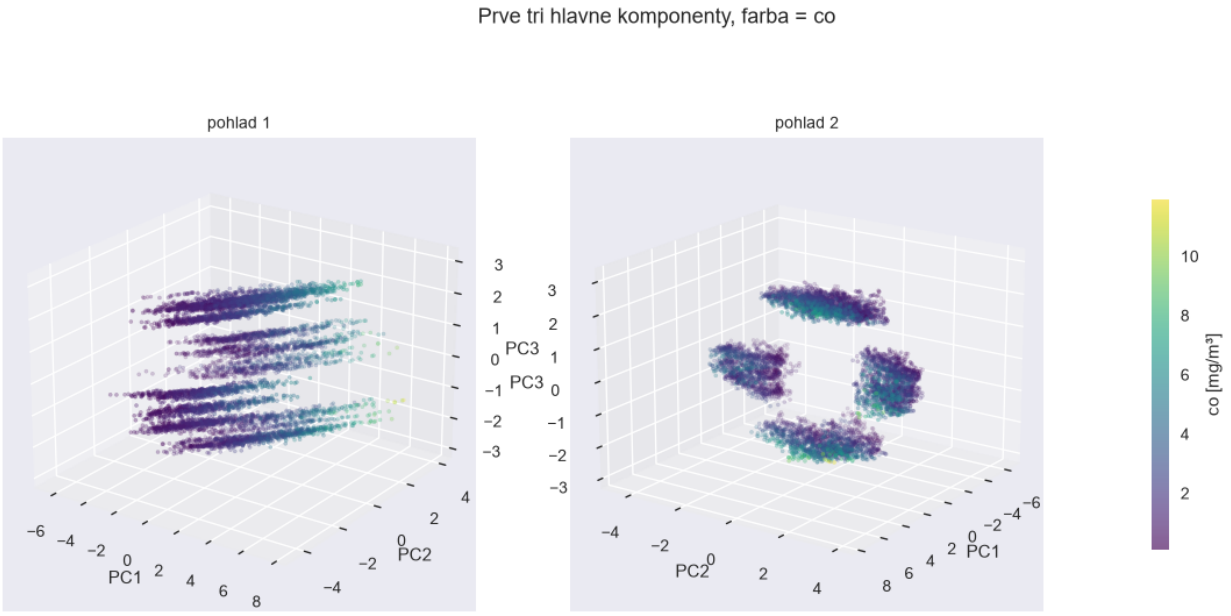
Obr. 10: Tri pôvodné príznaky z dvoch uhlov, farba je **co**.

Body tvoria zakrivený oblúk: s rastúcim **sensor_nmhc** klesá **sensor_nox** a farba ide z fialovej na žltú. Vysoké CO je len v rohu s vysokým **sensor_nmhc** a nízkym **sensor_nox**, závislosť je hladká, monotónna a

nelineárna. Os **hour** ukazuje denný cyklus: v noci (1. až 6. hodina) sú všetky body v úzkom fialovom páse, najvyššie hodnoty sú okolo 8. až 9. a 18. až 20. hodiny, v dopravných špičkách.

3.2 3D graf po redukcii dimenzie

PCA hľadá nové osi ako lineárne kombinácie pôvodných príznakov zoradené podľa vysvetleného rozptylu. Spustil som ju na normalizovaných 17 vstupoch bez **co**, nastavenú na trénovacej množine.



Obr. 11: Prvé tri hlavné komponenty z dvoch uhlov, farba je **co**.

Prvé tri komponenty vysvetľujú len **60 percent** rozptylu (26 + 20 + 14). Čo každá os znamená (váhy pôvodných príznakov):

- **PC1, os znečistenia**: kladné váhy všetkých senzorov (**sensor_nmhc** 0,45, **sensor_co** 0,41, **sensor_no2** 0,41, **sensor_o3** 0,39) a záporná **sensor_nox** ($-0{,}38$). Čím väčšie PC1, tým viac znečistenia. S **co** koreluje na 0,83, farba sa v grafe mení hlavne pozdĺž tejto osi.
- **PC2, os počasia**: záporná **temperature** ($-0{,}44$) a leto ($-0{,}41$), kladná **humidity** (0,32), zima (0,35) a **month_cos** (0,45). Veľké PC2 znamená chladno a vlhko. S **co** koreluje na 0,36.
- **PC3, os kalendára**: takmer len **month_sin** (0,56), **season_spring** (0,56) a **season_autumn** ($-0{,}48$). S **co** nesúvisí (0,08). Mesiac má len 12 hodnôt, preto body ležia v rovnobežných vrstvách, každá vrstva je jeden mesiac.

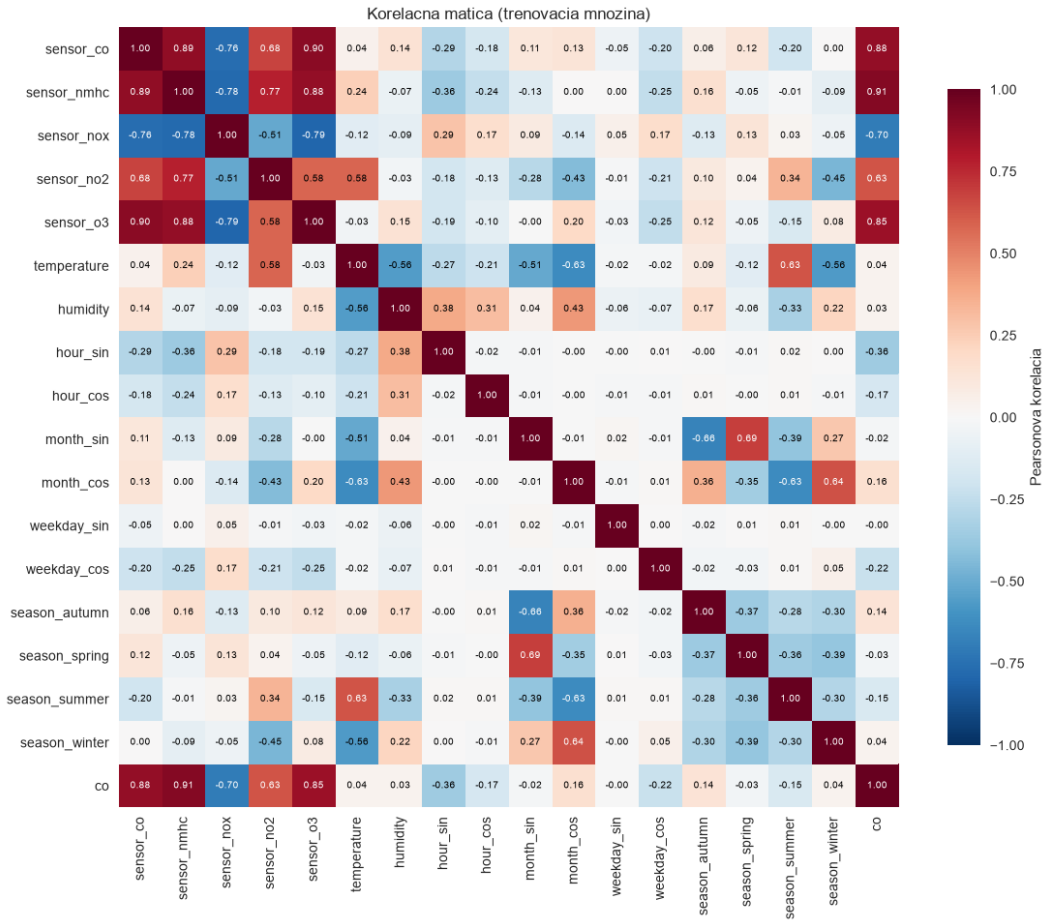
3.3 Porovnanie grafov

Graf z pôvodných príznakov je na analýzu CO lepší: osi majú fyzikálny význam a vidno nelineárny tvar závislosti aj dopravné špičky. PCA graf zachováva informáciu zo všetkých 17 príznakov, ale zobrazí len 60 percent rozptylu a osi treba čítať z váh. PCA maximalizuje rozptyl vstupov bez ohľadu na výstup, preto dve z troch osí minie na ročné obdobie a mesiac, ktoré s CO súvisia slabo.

4 Výber podmnožiny príznakov

Najúspešnejší model SVM (RBF, C = 10) som natrénoval znova na troch zmenšených množinách, s rovnakým rozdelením a škálovaním.

4.1 Podľa korelačnej matice



Obr. 12: Korelačná matica vstupov a výstupu na trénovacej množine.

S **co** silno korelujú len senzory (0,63 až 0,91), slabo **hour_sin** (0,36) a **weekday_cos** (0,22), ostatné pod 0,17. Prah $|r| \geq 0{,}2$ ponechá **7 príznakov** (päť senzorov, **hour_sin**, **weekday_cos**), vyradí teplotu, vlhkosť, mesiac a **season**. Výsledok **R^2 test 0,933**, RMSE 0,374. Teplota a vlhkosť s CO lineárne nekorelujú, ale SVM z nich niečo vyťaží nelineárne, korelácia to nevidí.

4.2 Podľa dôležitosti príznakov z ensemble modelu

Príznaky zoradené podľa dôležitosti z Random Forestu beriem, kým kumulatívna dôležitosť nedosiahne 95 percent: **9 príznakov** (päť senzorov, **hour_sin**, **temperature**, **hour_cos**, **humidity**), vyradené mesiac, deň v týždni a ročné obdobie. Výsledok **R^2 test 0,941**, RMSE 0,352, najlepší z troch výberov. Oproti korelácii sa sem dostali teplota a vlhkosť, lebo les meria aj nelineárne a kombinované efekty.

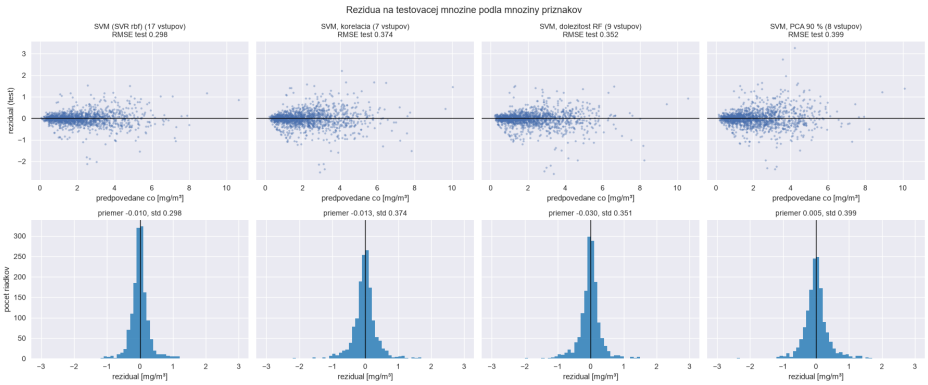
4.3 Podľa variancie pomocou PCA

`PCA(n_components=0.90)` si zoberie toľko komponentov, koľko treba na 90 percent rozptylu: **8 komponentov** (skutočne 92,9 percenta). Výsledok **R^2 test 0,924**, RMSE 0,399, najhorší z troch. PCA vyberá podľa rozptylu vstupov, nie podľa vzťahu k výstupu, a časť informácie o CO leží v komponentoch s malým rozptylom, ktoré sa zahodia.

4.4 Porovnanie výsledkov

model	pocet vstupov	MSE train	MSE test	RMSE train	RMSE test	R2 train	R2 test	R2 rozdiel (train - test)
SVM (SVR rbf)	17	0.0748	0.0888	0.2735	0.2979	0.9639	0.9573	0.0066
SVM, korelacia	7	0.1471	0.1400	0.3836	0.3742	0.9289	0.9327	-0.0038
SVM, dolezitost RF	9	0.1245	0.1237	0.3529	0.3516	0.9398	0.9406	-0.0008
SVM, PCA 90 %	8	0.1458	0.1592	0.3819	0.3991	0.9296	0.9235	0.0061

Obr. 13: SVM na všetkých 17 príznakoch a na troch zmenšených množinách.



Obr. 14: Rezíduá na testovacej množine podľa množiny príznakov.

Žiadny výber neprekonal pôvodných 17 príznakov (0,957): dôležitosť RF 0,941, korelácia 0,933, PCA 0,924. Rezíduá majú stále priemer blízko nuly a symetrický tvar, len sú širšie (0,35 až 0,40 oproti 0,30), najviac pri špičkách nad 5 mg/m³, kde PCA stráca najviac (chyba 0,67 oproti 0,44). Dáta majú jeden dominantný príznak (**sensor_nmhc** sám dá 0,885) a zvyšné prispievajú po troche, takže každý výber niečo stratí. Najlepší pomer dáva výber podľa dôležitosti: 9 vstupov za stratu 0,017 R^2.

Záver

- **Dáta**: z 9 507 riadkov zostalo 7 297, 17 vstupov (**season** one-hot, čas cyklicky sin/cos), rozdelenie 80/20, štandardizácia na trénovacej množine.
- **Modely**: strom R^2 test 0,910, Random Forest 0,940, **SVM (RBF, C = 10) 0,957** s RMSE 0,30 mg/m³. Modely sú nestranné, chyba rastie pri vysokých koncentráciách.
- **Redukcia dimenzie**: vybrané príznaky ukazujú hladkú nelineárnu závislosť a dopravné špičky, PCA zhrnie senzory do jednej osi, ale ďalšie dve minie na ročné obdobie.
- **Výber príznakov**: dôležitosť RF (9 vstupov) 0,941, korelácia (7) 0,933, PCA 90 percent (8) 0,924, žiadny neprekonal plnú množinu.
- Nepovinné úlohy neboli riešené.

Použitie nástrojov umelej inteligencie

Pri vypracovaní zadania bol ako pomocník použitý nástroj umelej inteligencie Claude (Anthropic). Nástroj bol využitý na správu a úpravu dokumentu v systéme LaTeX, sumarizáciu výsledkov jednotlivých úloh a pomoc pri formulácii textu. Postup riešenia, konfigurácie a výsledný obsah práce boli skontrolované autorom, ktorý za obsah práce zodpovedá.